

Instituto Tecnológico de Costa Rica

Escuela de Ingeniería en Computación

Base de Datos II

Proyecto II

Prof. Erick F. Hernandez Bonilla

Paulo César Herrera Arias

2023107673

Josué Santiago Hidalgo Sandoval

2024800128

Ian Sebastián Ugalde Muñoz

2024124076

Dayron Josué Porras Pérez

2023124693

San José Junio, 2026

Tabla de Contenidos

Arquitectura de la solución.....	3
Bases de Datos.....	5
Tecnologías utilizadas.....	7
Uso de IA.....	8
Modelos de Datos — MongoDB.....	9
Análisis 1: conflict_heatmap.....	9
Análisis 2: top_news_countries.....	9
Análisis 3: tone_source_correlation.....	10
Análisis 4: cameo_distribution.....	10
Análisis 5: actor_interaction_matrix.....	11
Análisis 6: media_coverage_ratio.....	12
Análisis 7: sentiment_trend.....	12
Análisis 8: conflict_pairs.....	13
Análisis 9: escalation_events.....	13
Análisis 10 — religion_conflict_cluster.....	14
Análisis 11: gkg_themes_continent.....	14
Análisis 12: top_organizations.....	15
Análisis 13: tone_conflict_lag.....	15
Análisis 14: diplomatic_network.....	16
Análisis 15: source_diversity_index.....	17
Análisis 16: ethnic_conflicts.....	17
Análisis 17: breaking_news.....	18
Análisis 18: extreme_tone_events.....	18
Análisis 19: top_article_coverage.....	19
Conclusiones.....	20
Referencias.....	21

Arquitectura de la solución

El proyecto utiliza una arquitectura por capas para descargar, procesar, almacenar y visualizar información sobre eventos.

El flujo principal de la arquitectura es el siguiente:

GDELT → Loader → Parquet → Apache Spark → MongoDB → Flask Dashboard




Figura 01 – Diagrama de Componentes

La primera capa corresponde a GDELT, que funciona como la fuente de datos del proyecto y publica información actualizada sobre eventos, menciones y noticias mundiales.

El componente Loader, está hecho en Python, este se encarga de descargar los archivos de GDELT, limpiar los datos y convertirlos de formato CSV a archivos Parquet. Estos archivos funcionan como almacenamiento intermedio y son compartidos con los demás componentes mediante los volúmenes configurados en Docker.

Posteriormente, el clúster de Apache Spark lee los archivos Parquet y ejecuta todos los análisis definidos en el proyecto. Los resultados generados por Spark se almacenan en MongoDB. Cada análisis utiliza una colección diferente, por lo que el dashboard puede consultar directamente los resultados sin tener que volver a procesar todos los datos.

Finalmente, la aplicación Flask se conecta a MongoDB, obtiene los resultados y los muestra en un dashboard web utilizando plantillas HTML y gráficos desarrollados con Chart.js.

Todos los componentes principales se ejecutan dentro de contenedores administrados mediante Docker Compose, lo que permite que el loader, Spark, MongoDB y el dashboard se comuniquen dentro de una misma red.

El proyecto también incluye Airflow como componente opcional para automatizar la ejecución periódica del loader y de los trabajos de Spark. Además, incluye servicios de HDFS como apoyo para almacenamiento distribuido, aunque el flujo principal implementado utiliza los archivos Parquet compartidos mediante volúmenes de Docker.

Bases de Datos

El flujo de procesamiento comienza con la descarga de archivos desde GDELT. El loader procesa los datos descargados y los almacena en formato Parquet dentro de un volumen compartido de Docker.

Los archivos Parquet son utilizados como almacenamiento temporal, ya que permiten guardar grandes cantidades de información de forma comprimida y facilitan su lectura mediante Spark.

Posteriormente, Spark realiza los análisis definidos en el proyecto. Entre estos análisis se encuentran conteos de eventos, países con mayor actividad, análisis de sentimiento, actores involucrados y actividad por día de la semana.

Los resultados procesados se almacenan en MongoDB. Cada análisis utiliza una colección independiente. Por ejemplo, el análisis 19 guarda sus resultados en la colección:

`weekday_activity`

Esta colección contiene documentos con una estructura similar a la siguiente:

```
{  
  
  "weekday_num": 1,  
  
  "weekday_name": "Lunes",  
  
  "event_count": 250  
}
```

Finalmente, Flask consulta las colecciones de MongoDB y envía los datos a las plantillas HTML para que sean mostrados en el dashboard.

El flujo completo es:

- Descargar datos de GDELT.
- Convertir los datos a formato Parquet.

- Procesar los datos con Spark.
- Guardar los resultados en MongoDB.
- Consultar los resultados desde Flask.
- Mostrar los análisis en gráficos y tablas.

Tecnologías utilizadas

El proyecto utiliza las siguientes tecnologías:

- **Docker Compose:** permite ejecutar y comunicar todos los componentes del proyecto mediante contenedores.
- **Python:** Se utiliza para la descarga, transformación, procesamiento y visualización de los datos.
- **Pandas:** Permite limpiar y transformar los archivos descargados desde GDELT.
- **PyArrow y Parquet:** Se utilizan para almacenar los datos procesados de forma comprimida y eficiente.
- **Apache Spark:** Ejecuta los análisis sobre grandes cantidades de datos.
- **MongoDB:** Almacena los resultados de los análisis en colecciones de documentos.
- **Flask:** funciona como backend del dashboard y proporciona las rutas y API necesarias.
- **PyMongo:** Permite la comunicación entre Flask, Spark y MongoDB.
- **Jinja2:** permite generar las páginas HTML desde Flask.
- **Chart.js:** se utiliza para mostrar los resultados mediante gráficos.
- **HTML, CSS y JavaScript:** se utilizan para construir la interfaz web del dashboard.

Estas tecnologías permiten que el proyecto realice el proceso completo de descarga, almacenamiento, análisis y visualización de datos de GDELT.

Uso de IA

Herramientas de Inteligencia Artificial Utilizadas:

- ChatGPT(versión gratuita): IA Generativa
- Claude (versión gratuita): IA Generativa
- Windsurf (version gratuita): IDE con IA Generativa

Se usó para:

- La Inteligencia Artificial se utilizó como una herramienta de apoyo durante el desarrollo del proyecto, principalmente para acelerar tareas de programación, documentación y análisis de datos.
- Mediante herramientas de IA generativa fue posible obtener sugerencias de código para componentes del pipeline ETL, consultas sobre Apache Spark, MongoDB y Docker, así como apoyo en la generación de documentación técnica y resolución de problemas.
- Además, la IA facilitó la comprensión de los datos obtenidos de GDELT y la identificación de posibles análisis para su visualización en el dashboard. Sin embargo, todas las soluciones propuestas fueron revisadas, adaptadas y validadas por los integrantes del proyecto antes de su implementación.

Modelos de Datos — MongoDB

Análisis 1: conflict_heatmap

Intensidad de conflictos por país y día (escala Goldstein). Solo incluye eventos QuadClass ≥ 3.

Índices: {country, date} | {date} | {avg_goldstein}

Campo	Tipo	Descripción
country	String	Código FIPS 10-4 del país (ej. NI, RS, GM)
date	Integer	Fecha YYYYMMDD
avg_goldstein	Double	Promedio GoldsteinScale del día (-10 a +10)
event_count	Integer	Número de eventos de conflicto en ese día
avg_mentions	Double	Promedio de menciones por evento

Análisis 2: top_news_countries

Top 10 países que generan más eventos noticiosos por día, rankeados por volumen.

Índices: {date, rank} | {country, date}

Campo	Tipo	Descripción
country	String	Código FIPS del país
date	Integer	Fecha YYYYMMDD
event_count	Integer	Número de eventos registrados ese día
rank	Integer	Posición en el ranking diario (1 = más eventos)

Análisis 3: tone_source_correlation

Correlación de Pearson entre el tono promedio (AvgTone) y el número de fuentes noticiosas por país/día.

Índices: {country, date} | {tone_sources_correlation}

Campo	Tipo	Descripción
country	String	Código FIPS del país
date	Integer	Fecha YYYYMMDD
avg_tone	Double	Promedio de AvgTone del día
avg_sources	Double	Promedio de NumSources del día
tone_sources_correlation	Double	Correlación de Pearson entre tono y fuentes
sample_size	Integer	Número de eventos usados en el cálculo

Análisis 4: cameo_distribution

Distribución de los 20 tipos base de eventos CAMEO por región geográfica y día.

Índices: {region, date} | {EventRootCode}

Campo	Tipo	Descripción
EventRootCode	String	Código raíz CAMEO (01–20)
event_description	String	Descripción del tipo de evento (ej. Amenazar, Atacar)
region	String	Región geográfica (North America, Middle East, etc.)
date	Integer	Fecha YYYYMMDD
event_count	Integer	Número de eventos de ese tipo en esa región y día

Análisis 5: actor_interaction_matrix

Matriz de frecuencia de interacciones entre tipos de actores (Actor1Type1Code vs Actor2Type1Code).

Índices: {actor1_type, actor2_type} | {event_count}

Campo	Tipo	Descripción
actor1_type	String	Tipo del actor 1 (GOV, MIL, REB, BUS, etc.)
actor2_type	String	Tipo del actor 2
event_count	Integer	Número total de interacciones entre ambos tipos
avg_goldstein	Double	Goldstein promedio de esas interacciones
avg_tone	Double	Tono promedio de esas interacciones

Análisis 6: media_coverage_ratio

Razón menciones/evento por país: indica qué países generan más cobertura mediática relativa.

Índices: {country, date} | {mentions_per_event}

Campo	Tipo	Descripción
country	String	Código FIPS del país
date	Integer	Fecha YYYYMMDD
total_mentions	Integer	Suma de NumMentions del país ese día
total_events	Integer	Número de eventos del país ese día
mentions_per_event	Double	Razón total_mentions / total_events

Análisis 7: sentiment_trend

Tendencia de AvgTone por país con promedio móvil de 3 días (ventana ajustada a retención real de datos).

Índices: {country, date}

Campo	Tipo	Descripción
country	String	Código FIPS del país
date	Integer	Fecha YYYYMMDD
avg_tone	Double	Promedio de AvgTone del día
moving_avg_3d	Double	Promedio móvil de 3 días del AvgTone

Análisis 8: conflict_pairs

Pares de países (por código ISO de actor) que entran en conflicto con mayor frecuencia.

Índices: {actor1_country, actor2_country} | {conflict_count} | {date}

Campo	Tipo	Descripción
actor1_country	String	Código ISO del Actor 1 (ej. UKR, IRN)
actor2_country	String	Código ISO del Actor 2
date	Integer	Fecha YYYYMMDD
conflict_count	Integer	Número de eventos de conflicto entre el par
avg_goldstein	Double	Goldstein promedio de esos conflictos

Análisis 9: escalation_events

Eventos donde más del 50% de sus menciones de las últimas 24h se concentran en 1 hora (escalation_ratio > 0.5).

Índices: {escalation_ratio} | {mention_hour}

Campo	Tipo	Descripción
GlobalEventID	Integer	ID único del evento GDELT
mention_hour	Timestamp	Hora en que se detectó la escalada
mentions_last_24h	Integer	Total de menciones en las 24h previas
mentions_this_hour	Integer	Menciones en esa hora específica
escalation_ratio	Double	$\frac{\text{mentions_this_hour}}{(\text{mentions_last_24h} + 1)}$

Análisis 10 — religion_conflict_cluster

Eventos de conflicto agrupados por religión del actor y región geográfica.

Índices: {religion, region} | {event_count}

Campo	Tipo	Descripción
religion	String	Código de religión (Actor1Religion1Code o Actor2Religion1Code)
region	String	Región geográfica del evento
date	Integer	Fecha YYYYMMDD
event_count	Integer	Número de conflictos con ese grupo religioso en esa región
avg_goldstein	Double	Intensidad promedio de esos conflictos

Análisis 11: gkg_themes_continent

Top 10 temas del Global Knowledge Graph (GKG) por continente y año.

Índices: {continent, year, rank} | {theme}

Campo	Tipo	Descripción
theme	String	Nombre del tema GKG (campo V2Themes)
continent	String	Continente de origen (Americas, Asia, Europe, Africa, Oceania)
year	String	Año (YYYY)
mention_count	Integer	Número de menciones del tema ese año/continente
rank	Integer	Posición en el top 10 del continente/año

Análisis 12: top_organizations

Top 20 organizaciones más mencionadas globalmente por día (campo Organizations del GKG).

Índices: {date, rank} | {organization}

Campo	Tipo	Descripción
organization	String	Nombre de la organización
date	String	Fecha YYYYMMDD
mention_count	Integer	Número de menciones en ese día
rank	Integer	Posición en el ranking diario

Análisis 13: tone_conflict_lag

Análisis de rezago: compara el tono mediático de un día con los conflictos registrados al día siguiente.

Índices: {country, date}

Campo	Tipo	Descripción
country	String	Código FIPS del país
date	Integer	Fecha de referencia YYYYMMDD
today_avg_tone	Double	AvgTone promedio del día de referencia
today_conflict_count	Integer	Eventos de conflicto del día de referencia
tomorrow_conflict_count	Integer	Eventos de conflicto del día siguiente

Análisis 14: diplomatic_network

Red de interacciones entre pares de países: diplomáticas (QuadClass 1-2) vs. conflictos (QuadClass 3-4).

Índices: {source_country, target_country} | {conflict_count}

Campo	Tipo	Descripción
source_country	String	Código FIPS del Actor 1
target_country	String	Código FIPS del Actor 2
diplomatic_count	Integer	Número de interacciones cooperativas/diplomáticas
conflict_count	Integer	Número de interacciones de conflicto
total_interactions	Integer	Total de eventos entre el par

Análisis 15: source_diversity_index

Índice de diversidad de fuentes por país: número de medios distintos que cubren sus eventos.

Índices: {country, date} | {source_diversity_index}

Campo	Tipo	Descripción
country	String	Código FIPS del país
date	Integer	Fecha YYYYMMDD
unique_sources	Integer	Número de fuentes (MentionSourceName) distintas
total_mentions	Integer	Total de menciones del país ese día
source_diversity_index	Double	$\log(\text{unique_sources} + 1)$

Análisis 16: ethnic_conflicts

Frecuencia de eventos de conflicto por grupo étnico de los actores.

Índices: {ethnicity, date} | {event_count}

Campo	Tipo	Descripción
ethnicity	String	Código étnico (Actor1EthnicCode o Actor2EthnicCode)
date	Integer	Fecha YYYYMMDD
event_count	Integer	Número de eventos de conflicto con ese grupo étnico
avg_goldstein	Double	Intensidad promedio de esos conflictos

Análisis 17: breaking_news

Eventos que acumulan más de 100 menciones en su primera hora desde su registro.

Índices: {first_mention_time} | {mentions_in_first_hour} | {country}

Campo	Tipo	Descripción
GlobalEventID	Integer	ID único del evento GDELT
first_mention_time	Timestamp	Timestamp de la primera mención registrada
mentions_in_first_hour	Integer	Menciones acumuladas en la primera hora
country	String	Código FIPS del país del evento
date	Integer	Fecha YYYYMMDD

Análisis 18: extreme_tone_events

Top 15 eventos con AvgTone más negativo y top 15 más positivo del periodo analizado.

Índices: {tone_extreme_type, AvgTone} | {country}

Campo	Tipo	Descripción
GlobalEventID	Integer	ID único del evento GDELT
country	String	Código FIPS del país del evento
EventRootCode	String	Código raíz CAMEO del tipo de evento
QuadClass	Integer	Clase del evento (1-4)
AvgTone	Double	Tono promedio de la cobertura del evento
NumMentions	Integer	Número de menciones del evento
Day	Integer	Fecha YYYYMMDD
tone_extreme_type	String	'most_negative' o 'most_positive'

Análisis 19: top_article_coverage

Ranking de países por volumen total de artículos (NumArticles) que cubren sus eventos.

Índices: {total_articles} | {country}

Campo	Tipo	Descripción
country	String	Código FIPS del país
total_articles	Integer	Suma total de NumArticles del país
avg_articles_per_event	Double	Promedio de artículos por evento
event_count	Integer	Número de eventos del país en el periodo

Conclusiones

El pipeline procesa actualizaciones cada 15 minutos, lo que permite observar cómo la actividad noticiosa global no es uniforme a lo largo del día. Los datos muestran concentraciones de eventos en franjas horarias específicas, consistentes con los ciclos laborales de los países más activos en generación de noticias, los cuales aparecen consistentemente en el top. Esto sugiere que la cobertura mediática sigue al día a día más que eventos espontáneos.

El mapa de calor basado en la escala Goldstein evidencia que los conflictos más intensos (valores cercanos a -10) se concentran en países con pocos eventos registrados en el periodo, lo que refleja una limitación estadística a causa de ventanas cortas de análisis. Sin embargo, países con mayor volumen de eventos como la India o Irán muestran promedios más representativos en el rango de -6 a -7, consistentes con su situación geopolítica. El análisis de pares confirma esto: Israel y el Líbano, Rusia y Estados Unidos son los pares con mayor frecuencia de conflicto, esto va acorde a la situación actual de conflictos mundiales.

El análisis #6 (razón menciones/evento) y el análisis #3 (correlación tono/fuentes) en conjunto muestran que los eventos que generan más cobertura mediática no son necesariamente los más frecuentes, sino los que tienen un tono más extremo. El análisis #18 de eventos con tono extremo muestra que los eventos con AvgTone más negativo acumulan más menciones que los positivos, lo que sugiere un sesgo de la prensa hacia la cobertura de malas noticias.

Referencias

Apache Spark (s. f.). Apache Spark 4.1.2 Documentation.

https://spark.apache.org.translate.goog/docs/latest/?_x_tr_sl=en&_x_tr_tl=es&_x_tr_hl=es&_x_tr_pto=tc

Schaefer, L. (2026, 4 marzo). Connect to a MongoDB Database Using Node.js. MongoDB.

<https://www.mongodb.com/blog/post/quick-start-nodejs-mongodb-how-to-get-connected-to-our-database>

Pérez Luque, M. (s. f.). Curso Apache Spark desde 0 - Tema 3 - SPARKSESSION, STAGES, JOBS, TRANSFORMACIONES Y ACCIONES [Video]. YouTube.

https://youtu.be/JY4Kbn62nyo?si=n1gtVQMNU_HyZQk

Python Software Foundation (s. f.). Python 3.14.6 Documentation.

<https://docs.python.org/3/>